

AN IMAGE IS WORTH 16X16 WORDS: TRANSFORMERS FOR IMAGE RECOGNITION AT SCALE

Alexey Dosovitskiy^{*,†}, Lucas Beyer^{*}, Alexander Kolesnikov^{*}, Dirk Weissenborn^{*},
Xiaohua Zhai^{*}, Thomas Unterthiner, Mostafa Dehghani, Matthias Minderer,
Georg Heigold, Sylvain Gelly, Jakob Uszkoreit, Neil Houlsby^{*,†}

^{*}equal technical contribution, [†]equal advising

Google Research, Brain Team

{adosovitskiy, neilhoulby}@google.com

摘要

尽管 Transformer 架构已成为自然语言处理任务的事实标准, 但其在计算机视觉中的应用仍然有限。在视觉领域, 注意力机制要么与卷积网络结合使用, 要么用于替代卷积网络的某些组件, 同时保持其整体结构不变。我们表明, 这种对 CNN 的依赖并非必要, 直接应用于图像块序列的纯 Transformer 在图像分类任务上也能取得非常好的效果。当在大量数据上进行预训练并迁移到多个中等规模或小型图像识别基准 (ImageNet、CIFAR-100、VTAB 等) 时, Vision Transformer (ViT) 取得了优异的结果, 且所需的计算资源远少于最先进的卷积网络。¹

1 引言

基于自注意力的架构, 特别是 Transformers (Vaswani et al., 2017), 已成为自然语言处理 (NLP) 的首选模型。主流方法是在大型文本语料库上进行预训练, 然后在较小的特定任务数据集上进行微调 (Devlin et al., 2019)。得益于 Transformers 的计算效率和可扩展性, 现在可以训练出前所未有的大规模模型, 参数量超过 1000 亿 (Brown et al., 2020; Lepikhin et al., 2020)。随着模型和数据集的增长, 性能饱和的迹象仍未出现。

然而, 在计算机视觉领域, 卷积架构仍占据主导地位 (LeCun et al., 1989; Krizhevsky et al., 2012; He et al., 2016)。受 NLP 成功的启发, 多项工作尝试将类 CNN 架构与自注意力相结合 (Wang et al., 2018; Carion et al., 2020), 有些则完全取代了卷积 (Ramachandran et al., 2019; Wang et al., 2020a)。后一类模型虽然在理论上高效, 但由于使用了特殊的注意力模式, 尚未能在现代硬件加速器上有效扩展。因此, 在大规模图像识别中, 经典的 ResNet 类架构仍然是最先进水平 (Mahajan et al., 2018; Xie et al., 2020; Kolesnikov et al., 2020)。

受 NLP 中 Transformer 扩展成功的启发, 我们实验了将标准 Transformer 直接应用于图像, 并尽可能少地进行修改。为此, 我们将图像分割为块, 并将这些块的线性嵌入序列作为输入提供给 Transformer。图像块的处理方式与 NLP 应用中的标记 (单词) 相同。我们以监督方式在图像分类任务上训练该模型。

当在中等规模数据集 (如 ImageNet) 上训练且未采用强正则化时, 这些模型的准确率较低, 比同等规模的 ResNet 低几个百分点。这一看似令人沮丧的结果可能在预期之中: Transformer 缺乏 CNN 固有的某些归纳偏置,

¹Fine-tuning code and pre-trained models are available at https://github.com/google-research/vision_transformer

例如平移等变性和局部性，因此在数据量不足的情况下泛化能力较差。

然而，如果模型在更大的数据集（1400 万至 3 亿张图像）上进行训练，情况就会发生变化。我们发现，大规模训练胜过归纳偏置。我们的 Vision Transformer (ViT) 在足够规模的预训练并迁移到数据点较少的任务时，取得了优异的结果。当在公开的 ImageNet-21k 数据集或内部的 JFT-300M 数据集上进行预训练时，ViT 在多个图像识别基准上接近或超越了最先进水平。具体而言，最佳模型在 ImageNet 上达到了 88.55% 的准确率，在 ImageNet-Real 上达到 90.72%，在 CIFAR-100 上达到 94.55%，在包含 19 个任务的 VTAB 套件上达到 77.63%。

2 相关工作

Transformers 由 Vaswani et al. (2017) 提出用于机器翻译，此后已成为许多 NLP 任务的最先进方法。基于 Transformer 的大型模型通常在大型语料库上进行预训练，然后针对当前任务进行微调：BERT (Devlin et al., 2019) 使用去噪自监督预训练任务，而 GPT 系列工作则使用语言建模作为其预训练任务 (Radford et al., 2018; Brown et al., 2020)。

将自注意力朴素地应用于图像要求每个像素关注其他所有像素。由于成本随像素数量呈二次方增长，这无法扩展到现实的输入尺寸。因此，为了在图像处理环境中应用 Transformers，过去曾尝试过几种近似方法。Parmar et al. (2018) 仅在每个查询像素的局部邻域内应用自注意力，而不是全局应用。这种局部多头点积自注意力块可以完全取代卷积 (Hu et al., 2019; Ramachandran et al., 2019; Zhao et al., 2020)。在另一类工作中，Sparse Transformers (Child et al., 2019) 采用全局自注意力的可扩展近似，以便适用于图像。另一种扩展注意力的方法是将其应用于不同大小的块 (Weissenborn et al., 2019)，极端情况下仅沿单个轴应用 (Ho et al., 2019; Wang et al., 2020a)。许多这些专门的注意力架构在计算机视觉任务上展示了令人鼓舞的结果，但需要复杂的工程才能在硬件加速器上高效实现。

与我们最相关的是 Cordonnier et al. (2020) 的模型，该模型从输入图像中提取大小为 2×2 的块，并在其上应用全自注意力。该模型与 ViT 非常相似，但我们的工作更进一步，证明了大规模预训练使原始 Transformer 能够与最先进的 CNN 相媲美（甚至更好）。此外，Cordonnier et al. (2020) 使用了 2×2 像素的小块尺寸，这使得模型仅适用于低分辨率图像，而我们也处理中等分辨率图像。

将卷积神经网络 (CNN) 与自注意力机制相结合也引起了广泛关注，例如通过增强特征图进行图像分类 (Bello et al., 2019)，或利用自注意力进一步处理 CNN 的输出，应用于目标检测 (Hu et al., 2018; Carion et al., 2020)、视频处理 (Wang et al., 2018; Sun et al., 2019)、图像分类 (Wu et al., 2020)、无监督物体发现 (Locatello et al., 2020) 或统一的文本-视觉任务 (Chen et al., 2020c; Lu et al., 2019; Li et al., 2019)。

另一个相关的近期模型是 image GPT (iGPT) (Chen et al., 2020a)，它在降低图像分辨率和色彩空间后，将 Transformer 应用于图像像素。该模型以生成式方式在无监督条件下训练，所得表示可随后通过微调或线性探测用于分类性能评估，在 ImageNet 上最高达到 72% 的准确率。

我们的工作丰富了日益增多的探索大规模图像识别的文献，其规模超越了标准的 ImageNet 数据集。利用额外数据源可在标准基准测试中取得最先进结果 (Mahajan et al., 2018; Touvron et al., 2019; Xie et al., 2020)。此外，Sun et al. (2017) 研究了 CNN 性能随数据集规模的扩展规律，Kolesnikov et al. (2020); Djolonga et al. (2020) 则对从 ImageNet-21k 和 JFT-300M 等大规模数据集进行的 CNN 迁移学习进行了实证探索。我们同样聚焦于这两个数据集，但训练的是 Transformer 而非先前工作中使用的基于 ResNet 的模型。




图 1: 模型概览。我们将图像分割为固定大小的块, 对每个块进行线性嵌入, 添加位置编码, 并将生成的向量序列输入标准 Transformer 编码器。为了执行分类任务, 我们采用在序列中添加一个额外的可学习“分类标记”的标准方法。Transformer 编码器的示意图灵感来源于 Vaswani et al. (2017)。

3 方法

在模型设计上, 我们尽可能遵循原始 Transformer (Vaswani et al., 2017)。这种有意简化的设置的一个优势在于, 可扩展的自然语言处理 Transformer 架构及其高效实现几乎可以开箱即用。

3.1 视觉 Transformer (ViT)

模型概览如图 1 所示。标准 Transformer 接收一维 token 嵌入序列作为输入。为了处理二维图像, 我们将图像 $\mathbf{x} \in \mathbb{R}^{H \times W \times C}$ 重塑为展平的二维 patch 序列 $\mathbf{x}_p \in \mathbb{R}^{N \times (P^2 \cdot C)}$, 其中 (H, W) 是原始图像的分辨率, C 是通道数, (P, P) 是每个图像 patch 的分辨率, $N = HW/P^2$ 是生成的 patch 数量, 这也作为 Transformer 的有效输入序列长度。Transformer 在所有层中使用恒定的潜在向量维度 D , 因此我们将 patch 展平并通过可训练的线性投影映射到 D 维 (公式 1)。我们将此投影的输出称为 patch 嵌入。

类似于 BERT 的 [class] token, 我们在嵌入 patch 序列前添加一个可学习的嵌入 ($z_0^0 = x_{class}$), 其在 Transformer 编码器输出处的状态 (z_L^0) 用作图像表示 $\mathbf{y}$ (公式 4)。在预训练和微调期间, 分类头均附加在 z_L^0 上。预训练时, 分类头由带有一个隐藏层的 MLP 实现; 微调时, 则由单个线性层实现。

位置嵌入被添加到 patch 嵌入中以保留位置信息。我们使用标准可学习的一维位置嵌入, 因为使用更先进的二维感知位置嵌入并未带来显著的性能提升 (附录 D.4)。由此得到的嵌入向量序列作为编码器的输入。

Transformer 编码器 (Vaswani et al., 2017) 由交替堆叠的多头自注意力层 (MSA, 见附录 A) 和 MLP 块 (式 2、3) 组成。在每个块之前应用层归一化 (LN), 并在每个块之后添加残差连接 (Wang et al., 2019; Baevski & Auli, 2019)。

MLP 包含两层，并使用 GELU 非线性激活函数。

$$\mathbf{z}_0 = [\mathbf{x}_{\text{class}}; \mathbf{x}_p^1 \mathbf{E}; \mathbf{x}_p^2 \mathbf{E}; \dots; \mathbf{x}_p^N \mathbf{E}] + \mathbf{E}_{\text{pos}}, \quad \mathbf{E} \in \mathbb{R}^{(P^2 \cdot C) \times D}, \mathbf{E}_{\text{pos}} \in \mathbb{R}^{(N+1) \times D} \quad (1)$$

$$\mathbf{z}'_\ell = \text{MSA}(\text{LN}(\mathbf{z}_{\ell-1})) + \mathbf{z}_{\ell-1}, \quad \ell = 1 \dots L \quad (2)$$

$$\mathbf{z}_\ell = \text{MLP}(\text{LN}(\mathbf{z}'_\ell)) + \mathbf{z}'_\ell, \quad \ell = 1 \dots L \quad (3)$$

$$\mathbf{y} = \text{LN}(\mathbf{z}_L^0) \quad (4)$$

归纳偏置。我们注意到，Vision Transformer 比 CNN 具有少得多的图像特定归纳偏置。在 CNN 中，局部性、二维邻域结构和平移等变性被嵌入到整个模型的每一层中。在 ViT 中，只有 MLP 层是局部且平移等变的，而自注意力层则是全局的。二维邻域结构的使用非常有限：仅在模型开始处通过将图像切割成 patch，以及在微调时针对不同分辨率图像调整位置嵌入时使用（如下所述）。除此之外，初始化时的位置嵌入不包含关于 patch 二维位置的信息，所有 patch 间的空间关系都必须从头学习。

混合架构。作为原始图像块的替代方案，输入序列可由 CNN 的特征图构成 (LeCun et al., 1989)。在该混合模型中，块嵌入投影 E （公式 1）应用于从 CNN 特征图中提取的块。作为一种特殊情况，块的空间尺寸可为 1×1 ，这意味着通过简单展平特征图的空间维度并投影到 Transformer 维度来获得输入序列。分类输入嵌入和位置嵌入按上述方式添加。

3.2 微调与更高分辨率

通常，我们在大数据集上预训练 ViT，并在（较小的）下游任务上进行微调。为此，我们移除预训练的预测头，并附加一个零初始化的 $D \times K$ 前馈层，其中 K 为下游类别数。在比预训练更高的分辨率下进行微调通常是有益的 (Touvron et al., 2019; Kolesnikov et al., 2020)。当输入更高分辨率的图像时，我们保持块大小不变，这导致有效序列长度增加。Vision Transformer 可以处理任意序列长度（受内存限制），然而，预训练的位置嵌入可能不再有意义。因此，我们根据其在原始图像中的位置对预训练的位置嵌入进行二维插值。请注意，这种分辨率调整和块提取是手动向 Vision Transformer 注入关于图像二维结构的归纳偏置的唯一环节。

4 实验

我们评估 ResNet、Vision Transformer (ViT) 和混合模型的表示学习能力。为了理解每个模型的数据需求，我们在不同规模的数据集上进行预训练，并评估许多基准任务。考虑到预训练的计算成本，ViT 表现非常优异，以较低的预训练成本在大多数识别基准上达到了最先进水平。最后，我们使用自监督进行了一项小规模实验，结果表明自监督 ViT 具有广阔的前景。

4.1 实验设置

数据集。为了探索模型的可扩展性，我们使用了包含 1k 个类别和 1.3M 张图像的 ILSVRC-2012 ImageNet 数据集（下文简称为 ImageNet）、其超集包含 21k 个类别和 14M 张图像的 ImageNet-21k (Deng et al., 2009)，以及包含 18k 个类别和 303M 张高分辨率图像的 JFT (Sun et al., 2017)。遵循 Kolesnikov et al. (2020)，我们对预训练数据集相对于下游任务的测试集进行了去重。我们将这些数据集上训练的模型迁移到几个基准任务：使用原始验证标签和清理后的 ReaL 标签的 ImageNet (Beyer et al., 2020)、CIFAR-10/100 (Krizhevsky, 2009)、Oxford-IIIT Pets (Parkhi et al., 2012) 和 Oxford Flowers-102 (Nilsback & Zisserman, 2008)。对于这些数据集，预处理遵循 Kolesnikov et al. (2020)。

Model	Layers	Hidden size D	MLP size	Heads	Params
ViT-Base	12	768	3072	12	86M
ViT-Large	24	1024	4096	16	307M
ViT-Huge	32	1280	5120	16	632M

Table 1: Details of Vision Transformer model variants.

我们还在 19 任务的 VTAB 分类套件上进行了评估 (Zhai et al., 2019b)。VTAB 评估低数据量下向多样化任务的迁移能力, 每个任务使用 1000 个训练样本。任务分为三组: Natural-tasks, 如上述任务、Pets、CIFAR 等; Specialized-tasks, 包括医学和卫星图像; 以及 Structured-tasks, 需要几何理解的任务, 如定位。

模型变体。我们的 ViT 配置基于 BERT 使用的配置 (Devlin et al., 2019), 如表 1 所示。“Base”和“Large”模型直接采用自 BERT, 我们添加了更大的“Huge”模型。在下文中, 我们使用简写符号来表示模型大小和输入块大小: 例如, ViT-L/16 表示输入块大小为 16×16 的“Large”变体。注意, Transformer 的序列长度与块大小的平方成反比, 因此块大小较小的模型计算成本更高。

对于基线 CNN, 我们使用 ResNet (He et al., 2016), 但将批归一化层 (Ioffe & Szegedy, 2015) 替换为组归一化 (Wu & He, 2018), 并使用标准化卷积 (Qiao et al., 2019)。这些改进提升了迁移效果 (Kolesnikov et al., 2020), 我们将修改后的模型记为“ResNet (BiT)”。对于混合模型, 我们将中间特征图输入到块大小为单个“像素”的 ViT 中。为了尝试不同的序列长度, 我们要么 (i) 取常规 ResNet50 第 4 阶段的输出, 要么 (ii) 移除第 4 阶段, 将相同数量的层放入第 3 阶段 (保持总层数不变), 并取这个扩展的第 3 阶段的输出。选项 (ii) 导致序列长度增加 4 倍, 且 ViT 模型计算成本更高。

训练与微调。我们使用 Adam (Kingma & Ba, 2015) 训练所有模型, 包括 ResNet, 参数设置为 $\beta_1 = 0.9$ 、 $\beta_2 = 0.999$, 批量大小为 4096, 并应用较高的权重衰减 0.1, 我们发现这对所有模型的迁移都有用 (附录 D.1 表明, 与常见做法相反, 在我们的设置中 Adam 对 ResNet 的效果略优于 SGD)。我们使用线性学习率预热和衰减, 详见附录 B.1。对于微调, 我们对所有模型使用带动量的 SGD, 批量大小为 512, 详见附录 B.1.1。对于表 2 中的 ImageNet 结果, 我们在更高分辨率下进行微调: ViT-L/16 为 512, ViT-H/14 为 518, 并使用了系数为 0.9999 的 Polyak & Juditsky (1992) 平均法 (Ramachandran et al., 2019; Wang et al., 2020b)。指标。我们通过少样本或微调准确率报告下游数据集的结果。微调准确率反映各模型在相应数据集上微调后的性能。少样本准确率通过求解正则化最小二乘回归问题获得, 该问题将训练图像子集的 (冻结) 表示映射至 $\{-1, 1\}^K$ 目标向量。此公式允许我们以闭式形式恢复精确解。尽管我们主要关注微调性能, 但在微调成本过高时, 有时使用线性少样本准确率进行快速的即时评估。

4.2 与最先进方法的比较

我们首先将最大的模型——ViT-H/14 和 ViT-L/16——与文献中最先进的 CNN 进行比较。第一个比较对象是 Big Transfer (BiT) (Kolesnikov et al., 2020), 它使用大型 ResNet 进行监督迁移学习。第二个是 Noisy Student (Xie et al., 2020), 这是一个大型 EfficientNet, 使用半监督学习在 ImageNet 和 JFT-300M (去除标签) 上训练得到。目前, Noisy Student 在 ImageNet 上是最先进的, 而 BiT-L 在其他报告的数据集上是最先进的。所有模型均在 TPUv3 硬件上训练, 我们报告了预训练每个模型所需的 TPUv3 核天数, 即用于训练的 TPU v3 核心数 (每芯片 2 个) 乘以以天为单位的训练时间。

表 2 展示了结果。在 JFT-300M 上预训练的较小 ViT-L/16 模型在所有任务上均优于 BiT-L (在同一数据集上预训练), 且训练所需的计算资源显著减少。更大的模型 ViT-H/14 进一步提升了性能, 尤其是在更具挑战性的数据集——ImageNet、CIFAR-100 和 VTAB 套件上。有趣的是, 这一

	Ours-JFT (ViT-H/14)	Ours-JFT (ViT-L/16)	Ours-I21k (ViT-L/16)	BiT-L (ResNet152x4)	Noisy Student (EfficientNet-L2)
ImageNet	88.55 ± 0.04	87.76 ± 0.03	85.30 ± 0.02	87.54 ± 0.02	88.4/88.5*
ImageNet Real	90.72 ± 0.05	90.54 ± 0.03	88.62 ± 0.05	90.54	90.55
CIFAR-10	99.50 ± 0.06	99.42 ± 0.03	99.15 ± 0.03	99.37 ± 0.06	—
CIFAR-100	94.55 ± 0.04	93.90 ± 0.05	93.25 ± 0.05	93.51 ± 0.08	—
Oxford-IIIT Pets	97.56 ± 0.03	97.32 ± 0.11	94.67 ± 0.15	96.62 ± 0.23	—
Oxford Flowers-102	99.68 ± 0.02	99.74 ± 0.00	99.61 ± 0.02	99.63 ± 0.03	—
VTAB (19 tasks)	77.63 ± 0.23	76.28 ± 0.46	72.72 ± 0.21	76.29 ± 1.70	—
TPUv3-core-days	2.5k	0.68k	0.23k	9.9k	12.3k

Table 2: Comparison with state of the art on popular image classification benchmarks. We report mean and standard deviation of the accuracies, averaged over three fine-tuning runs. Vision Transformer models pre-trained on the JFT-300M dataset outperform ResNet-based baselines on all datasets, while taking substantially less computational resources to pre-train. ViT pre-trained on the smaller public ImageNet-21k dataset performs well too. *Slightly improved 88.5% result reported in Touvron et al. (2020).




图 2: VTAB 在 Natural、Specialized 和 Structured 任务组中的性能分解。

模型在预训练时仍然比之前的最先进方法需要显著更少的计算量。然而,我们注意到预训练效率不仅受架构选择的影响,还受其他参数的影响,例如训练调度、优化器、权重衰减等。我们在第 4.4 节中提供了不同架构的性能与计算量的受控研究。最后,在公共 ImageNet-21k 数据集上预训练的 ViT-L/16 模型在大多数数据集上也表现良好,同时预训练所需资源更少:它可以使用具有 8 个核心的标准云 TPUv3 在大约 30 天内完成训练。

图 2 将 VTAB 任务分解为各自的组别,并与该基准测试中先前的 SOTA 方法进行比较: BiT、VIVI-a (在 ImageNet 和 Youtube 上共同训练的 ResNet, Tschannen et al., 2020), 以及 S4L-supervised (在 ImageNet 上进行监督加半监督学习, Zhai et al., 2019a)。ViT-H/14 在 Natural 和 Structured 任务上优于 BiT-R152x4 及其他方法。在 Specialized 任务上, 前两名模型的性能相似。

4.3 预训练数据需求

当在大型 JFT-300M 数据集上预训练时, Vision Transformer 表现良好。与 ResNet 相比, 其视觉归纳偏置较少, 那么数据集大小有多关键? 我们进行了两组实验。

首先, 我们在规模递增的数据集上对 ViT 模型进行预训练: ImageNet、ImageNet-21k 和 JFT-300M。为了提升在较小数据集上的性能, 我们优化了三个基本正则化参数——权重衰减、Dropout 和标签平滑。图 3 展示了在 ImageNet 上微调后的结果 (其他数据集的结果见表 5)²。当使用最小的数据集 ImageNet 进行预训练时, 尽管采用了 (适度的) 正则化, ViT-Large 模型的表现仍不如 ViT-Base 模型。在使用 ImageNet-21k 预训练时, 两者的表现相当。只有在使用 JFT-300M 时, 我们才能看到更大模型的完整优势。图 3 还展示了性能

²Note that the ImageNet pre-trained models are also fine-tuned, but again on ImageNet. This is because the resolution increase during fine-tuning improves the performance.




图 3: 迁移至 ImageNet。当在小规模数据集上预训练时, 大型 ViT 模型的表现不如 BiT ResNet (阴影区域), 但在更大规模的数据集上预训练时则表现优异。类似地, 随着数据集规模的增大, 较大的 ViT 变体逐渐超越较小的变体。




图 4: ImageNet 上线性少样本评估与预训练规模的关系。ResNet 在较小的预训练数据集上表现更优, 但较早达到性能平台; 而 ViT 在较大的预训练数据集上表现更佳。ViT-b 为隐藏维度减半的 ViT-B。




图 5: 不同架构 (Vision Transformers、ResNets 及混合模型) 的性能与预训练计算量的关系。在相同计算预算下, Vision Transformers 通常优于 ResNets。对于较小规模的模型, 混合模型优于纯 Transformer, 但随着模型规模增大, 这一差距消失。

不同尺寸 BiT 模型所覆盖的区域。BiT CNN 在 ImageNet 上优于 ViT, 但在更大的数据集上, ViT 反超。

其次, 我们在 9M、30M 和 90M 的随机子集以及完整的 JFT-300M 数据集上训练模型。我们对较小的子集不执行额外的正则化, 并在所有设置中使用相同的超参数。这样, 我们评估的是模型的内在属性, 而非正则化的影响。然而, 我们确实使用了早停法, 并报告训练期间达到的最佳验证准确率。为了节省结果, 我们报告少样本线性准确率而非完整微调准确率。图 4 包含结果。在较小的数据集上, 以相当的计算成本计, Vision Transformers 比 ResNets 过拟合更严重。例如, ViT-B/32 略快于 ResNet50; 它在 9M 子集上的表现差得多, 但在 90M+ 子集上表现更好。ResNet152x2 和 ViT-L/16 也是如此。这一结果强化了直觉, 即卷积归纳偏置对较小的数据集有用, 但对于较大的数据集, 直接从数据中学习相关模式就足够了, 甚至有益。

总体而言, ImageNet 上的少样本结果 (图 4) 以及 VTAB 上的低数据量结果 (表 2) 对于极低数据量的迁移似乎很有前景。对 ViT 少样本特性的进一步分析是未来工作的一个令人兴奋的方向。

4.4 规模研究


我们通过评估从 JFT-300M 的迁移性能, 对不同模型进行受控的缩放研究。在这种设置下, 数据规模不会成为模型性能的瓶颈, 我们评估每个模型的性能与预训练成本之间的关系。模型集包括: 7 个 ResNet, R50x1、R50x2、R101x1、R152x1、R152x2, 预训练 7 个 epoch, 加上 R152x2 和 R200x3, 预训练 14 个 epoch; 6 个 Vision Transformers, ViT-B/32、B/16、L/32、L/16, 预训练 7 个 epoch, 加上 L/16 和 H/14, 预训练 14 个 epoch; 以及 5 个混合模型, R50+ViT-B/32、B/16、L/32、L/16, 预训练 7 个 epoch, 加上 R50+ViT-L/16, 预训练 14 个 epoch (对于混合模型, 模型名称末尾的数字不代表补丁大小, 而是代表 ResNet 主干中的总下采样比率)。

图 5 包含迁移性能与总预训练计算量之间的关系 (关于计算成本的详细信息见附录 D.5)。每个模型的详细结果见附录中的表 6。可以观察到一些规律。首先, 在性能/计算权衡方面, Vision Transformers 优于 ResNets。ViT 达到相同性能所需的计算量大约少 $2 - 4 \times$ (基于 5 个数据集的平均值)。其次, 混合模型在小计算预算下略微优于 ViT, 但这种差异在较大模型中消失。这一结果有些令人惊讶, 因为人们可能期望卷积局部特征处理在任何尺寸下都能辅助 ViT。第三, Vision Transformers 在所尝试的范围内似乎并未饱和, 这激励了未来的缩放工作。

4.5 检查 Vision Transformer

为了初步理解 Vision Transformer 如何处理图像数据, 我们分析了其内部表示。Vision Transformer 的第一层将展平的图块线性投影到低维空间 (式 1)。图 7 (左) 展示了学习到的嵌入滤波器的主成分前几位。这些成分类似于用于表示每个图块内精细结构的低维基函数。

在投影之后, 一个学习到的位置嵌入被添加到图块表示中。图 7 (中间) 显示, 模型学会了通过位置嵌入的相似性来编码图像内的距离, 即距离较近的图块往往具有更相似的位置嵌入。此外, 行列结构显现出来; 同一行/列中的图块具有相似的嵌入。最后, 对于较大的网格, 有时可以观察到正弦结构 (附录 D)。位置嵌入学会表示二维图像拓扑结构这一事实, 解释了为什么手工设计的二维感知嵌入变体未能带来性能提升 (附录 D.4)。



自注意力机制使得 ViT 即使在最底层也能整合整个图像的信息。我们研究了网络利用这一能力的程度。具体而言, 我们基于注意力权重计算了信息整合所跨越的图像空间平均距离 (图 7, 右)。这种“注意力距离”类似于 CNN 中的感受野大小。

图 6: 输出 token 对输入空间注意力的代表性示例。详见附录 D.7。

我们发现, 某些注意力头在最底层就已经关注图像的绝大部分区域, 这表明模型确实利用了全局整合信息的能力。其他注意力头在低层始终表现出较小的注意力距离。这种高度局部化的注意力在 Transformer 之前应用 ResNet 的混合模型中不那么明显 (图 7, 右), 这表明它可能起着与 CNN 中早期卷积层类似的作用。此外, 注意力距离随网络深度增加而增大。总体而言, 我们发现模型关注的是对分类具有语义相关性的图像区域 (图 6)。

4.6 自监督

Transformer 在 NLP 任务上表现出令人印象深刻的性能。然而, 其成功不仅源于出色的可扩展性, 还得益于大规模自监督预训练 (Devlin




图 7: 左: ViT-L/32 初始线性嵌入的 RGB 值滤波器。中: ViT-L/32 位置嵌入的相似度。方块显示指定行和列的图像块位置嵌入与所有其他图像块位置嵌入之间的余弦相似度。右: 各注意力头和网络深度的关注区域大小。每个点表示某一层中 16 个注意力头之一在所有图像上的平均注意力距离。详见附录 D.7。

et al., 2019; Radford et al., 2018)。我们还对用于自监督的掩码补丁预测进行了初步探索, 模仿了 BERT 中使用的掩码语言建模任务。通过自监督预训练, 我们较小的 ViT-B/16 模型在 ImageNet 上达到了 79.9% 的准确率, 相比从头开始训练显著提高了 2%, 但仍比有监督预训练低 4%。附录 B.1.2 包含了更多细节。我们将对比学习预训练 (Chen et al., 2020b; He et al., 2020; Bachman et al., 2019; Hénaff et al., 2020) 的探索留作未来工作。

5 结论

我们探索了将 Transformer 直接应用于图像识别的方法。与以往在计算机视觉中使用自注意力的工作不同, 除了初始的图块提取步骤外, 我们没有在架构中引入特定于图像的归纳偏置。相反, 我们将图像解释为图块序列, 并使用 NLP 中标准的 Transformer 编码器对其进行处理。当结合大规模数据集上的预训练时, 这种简单但可扩展的策略效果出奇地好。因此, Vision Transformer 在许多图像分类数据集上达到或超越了最先进水平, 同时预训练成本相对较低。

虽然这些初步结果令人鼓舞, 但仍面临许多挑战。其中之一是将 ViT 应用于其他计算机视觉任务, 如检测和分割。我们的结果以及 Carion 等人 (2020) 的结果表明了这种方法的前景。另一个挑战是继续探索自监督预训练方法。我们的初步实验显示自监督预训练带来了改进, 但自监督预训练与大规模监督预训练之间仍存在巨大差距。最后, 进一步扩展 ViT 规模可能会带来性能的提升。

致谢

本研究在柏林、苏黎世和阿姆斯特丹完成。我们感谢 Google 的许多同事提供的帮助, 特别是 Andreas Steiner 在基础设施和代码开源发布方面给予的关键支持; Joan Puigcerver 和 Maxim Neumann 在大规模训练基础设施方面的协助; 以及 Dmitry Lepikhin、Aravindh Mahendran、Daniel Keysers、Mario Lucić、Noam Shazeer、Ashish Vaswani 和 Colin Raffel 的有益讨论。

REFERENCES

Samira Abnar 和 Willem Zuidema. Quantifying attention flow in transformers. In ACL, 2020.

- Alexei Baevski and Michael Auli. Adaptive input representations for neural language modeling. In *ICLR*, 2019.
- I. Bello, B. Zoph, Q. Le, A. Vaswani, and J. Shlens. Attention augmented convolutional networks. In *ICCV*, 2019.
- Lucas Beyer, Olivier J. Hénaff, Alexander Kolesnikov, Xiaohua Zhai, and Aäron van den Oord. Are we done with imagenet? *arXiv*, 2020.
- Tom B Brown, Benjamin Mann, Nick Ryder, Melanie Subbiah, Jared Kaplan, Prafulla Dhariwal, Arvind Neelakantan, Pranav Shyam, Girish Sastry, Amanda Askell, et al. Language models are few-shot learners. *arXiv*, 2020.
- Nicolas Carion, Francisco Massa, Gabriel Synnaeve, Nicolas Usunier, Alexander Kirillov, and Sergey Zagoruyko. End-to-end object detection with transformers. In *ECCV*, 2020.
- Mark Chen, Alec Radford, Rewon Child, Jeff Wu, and Heewoo Jun. Generative pretraining from pixels. In *ICML*, 2020a.
- Ting Chen, Simon Kornblith, Mohammad Norouzi, and Geoffrey E. Hinton. A simple framework for contrastive learning of visual representations. In *ICML*, 2020b.
- Yen-Chun Chen, Linjie Li, Licheng Yu, Ahmed El Kholy, Faisal Ahmed, Zhe Gan, Yu Cheng, and Jingjing Liu. UNITER: UNiversal Image-TExt Representation Learning. In *ECCV*, 2020c.
- Rewon Child, Scott Gray, Alec Radford, and Ilya Sutskever. Generating long sequences with sparse transformers. *arXiv*, 2019.
- Jean-Baptiste Cordonnier, Andreas Loukas, and Martin Jaggi. On the relationship between self-attention and convolutional layers. In *ICLR*, 2020.
- J. Deng, W. Dong, R. Socher, L. Li, Kai Li, and Li Fei-Fei. Imagenet: A large-scale hierarchical image database. In *CVPR*, 2009.
- Jacob Devlin, Ming-Wei Chang, Kenton Lee, and Kristina Toutanova. BERT: Pre-training of deep bidirectional transformers for language understanding. In *NAACL*, 2019.
- Josip Djolonga, Jessica Yung, Michael Tschannen, Rob Romijnders, Lucas Beyer, Alexander Kolesnikov, Joan Puigcerver, Matthias Minderer, Alexander D’Amour, Dan Moldovan, Sylvain Gelly, Neil Houlsby, Xiaohua Zhai, and Mario Lucic. On robustness and transferability of convolutional neural networks. *arXiv*, 2020.
- Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. Deep residual learning for image recognition. In *CVPR*, 2016.
- Kaiming He, Haoqi Fan, Yuxin Wu, Saining Xie, and Ross Girshick. Momentum contrast for unsupervised visual representation learning. In *CVPR*, 2020.
- Jonathan Ho, Nal Kalchbrenner, Dirk Weissenborn, and Tim Salimans. Axial attention in multidimensional transformers. *arXiv*, 2019.
- Han Hu, Jiayuan Gu, Zheng Zhang, Jifeng Dai, and Yichen Wei. Relation networks for object detection. In *CVPR*, 2018.
- Han Hu, Zheng Zhang, Zhenda Xie, and Stephen Lin. Local relation networks for image recognition. In *ICCV*, 2019.
- Zilong Huang, Xinggang Wang, Yunchao Wei, Lichao Huang, Humphrey Shi, Wenyu Liu, and Thomas S. Huang. Ccnet: Criss-cross attention for semantic segmentation. In *ICCV*, 2020.
- Olivier J. Hénaff, Aravind Srinivas, Jeffrey De Fauw, Ali Razavi, Carl Doersch, S. M. Ali Eslami, and Aaron van den Oord. Data-efficient image recognition with contrastive predictive coding. In *ICML*, 2020.

- Sergey Ioffe and Christian Szegedy. Batch normalization: Accelerating deep network training by reducing internal covariate shift. 2015.
- Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. In *ICLR*, 2015.
- Alexander Kolesnikov, Lucas Beyer, Xiaohua Zhai, Joan Puigcerver, Jessica Yung, Sylvain Gelly, and Neil Houlsby. Big transfer (BiT): General visual representation learning. In *ECCV*, 2020.
- Alex Krizhevsky. Learning multiple layers of features from tiny images. Technical report, 2009.
- Alex Krizhevsky, Ilya Sutskever, and Geoffrey E. Hinton. Imagenet classification with deep convolutional neural networks. In *NIPS*, 2012.
- Y. LeCun, B. Boser, J. Denker, D. Henderson, R. Howard, W. Hubbard, and L. Jackel. Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1:541–551, 1989.
- Dmitry Lepikhin, Hyoungho Lee, Yuanzhong Xu, Dehao Chen, Orhan Firat, Yanping Huang, Maxim Krikun, Noam Shazeer, and Zhifeng Chen. Gshard: Scaling giant models with conditional computation and automatic sharding. *arXiv*, 2020.
- Liunian Harold Li, Mark Yatskar, Da Yin, Cho-Jui Hsieh, and Kai-Wei Chang. VisualBERT: A Simple and Performant Baseline for Vision and Language. In *Arxiv*, 2019.
- Francesco Locatello, Dirk Weissenborn, Thomas Unterthiner, Aravindh Mahendran, Georg Heigold, Jakob Uszkoreit, Alexey Dosovitskiy, and Thomas Kipf. Object-centric learning with slot attention. *arXiv*, 2020.
- Jiasen Lu, Dhruv Batra, Devi Parikh, and Stefan Lee. ViLBERT: Pretraining Task-Agnostic Visiolinguistic Representations for Vision-and-Language Tasks. In *NeurIPS*. 2019.
- Dhruv Mahajan, Ross Girshick, Vignesh Ramanathan, Kaiming He, Manohar Paluri, Yixuan Li, Ashwin Bharambe, and Laurens van der Maaten. Exploring the limits of weakly supervised pretraining. In *ECCV*, 2018.
- M. Nilsback and A. Zisserman. Automated flower classification over a large number of classes. In *ICVGIP*, 2008.
- Omkar M. Parkhi, Andrea Vedaldi, Andrew Zisserman, and C. V. Jawahar. Cats and dogs. In *CVPR*, 2012.
- Niki Parmar, Ashish Vaswani, Jakob Uszkoreit, Lukasz Kaiser, Noam Shazeer, Alexander Ku, and Dustin Tran. Image transformer. In *ICML*, 2018.
- B. T. Polyak and A. B. Juditsky. Acceleration of stochastic approximation by averaging. *SIAM Journal on Control and Optimization*, 30(4):838–855, 1992. doi: 10.1137/0330046. URL <https://doi.org/10.1137/0330046>.
- Siyuan Qiao, Huiyu Wang, Chenxi Liu, Wei Shen, and Alan Yuille. Weight standardization. *arXiv preprint arXiv:1903.10520*, 2019.
- Alec Radford, Karthik Narasimhan, Tim Salimans, and Ilya Sutskever. Improving language understanding with unsupervised learning. *Technical Report*, 2018.
- Alec Radford, Jeff Wu, Rewon Child, David Luan, Dario Amodei, and Ilya Sutskever. Language models are unsupervised multitask learners. *Technical Report*, 2019.
- Prajit Ramachandran, Niki Parmar, Ashish Vaswani, Irwan Bello, Anselm Levskaya, and Jon Shlens. Stand-alone self-attention in vision models. In *NeurIPS*, 2019.
- Chen Sun, Abhinav Shrivastava, Saurabh Singh, and Abhinav Gupta. Revisiting unreasonable effectiveness of data in deep learning era. In *ICCV*, 2017.
- Chen Sun, Austin Myers, Carl Vondrick, Kevin Murphy, and Cordelia Schmid. Videobert: A joint model for video and language representation learning. In *ICCV*, 2019.

- Hugo Touvron, Andrea Vedaldi, Matthijs Douze, and Herve Jegou. Fixing the train-test resolution discrepancy. In *NeurIPS*. 2019.
- Hugo Touvron, Andrea Vedaldi, Matthijs Douze, and Herve Jegou. Fixing the train-test resolution discrepancy: Fixefficientnet. *arXiv preprint arXiv:2003.08237*, 2020.
- Michael Tschanen, Josip Djolonga, Marvin Ritter, Aravindh Mahendran, Neil Houlsby, Sylvain Gelly, and Mario Lucic. Self-supervised learning of video-induced visual invariances. In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, June 2020.
- Ashish Vaswani, Noam Shazeer, Niki Parmar, Jakob Uszkoreit, Llion Jones, Aidan N Gomez, Łukasz Kaiser, and Illia Polosukhin. Attention is all you need. In *NIPS*, 2017.
- Huiyu Wang, Yukun Zhu, Bradley Green, Hartwig Adam, Alan Yuille, and Liang-Chieh Chen. Axial-deeplab: Stand-alone axial-attention for panoptic segmentation. In *ECCV*, 2020a.
- Huiyu Wang, Yukun Zhu, Bradley Green, Hartwig Adam, Alan Yuille, and Liang-Chieh Chen. Axial-deeplab: Stand-alone axial-attention for panoptic segmentation. *arXiv preprint arXiv:2003.07853*, 2020b.
- Qiang Wang, Bei Li, Tong Xiao, Jingbo Zhu, Changliang Li, Derek F. Wong, and Lidia S. Chao. Learning deep transformer models for machine translation. In *ACL*, 2019.
- Xiaolong Wang, Ross Girshick, Abhinav Gupta, and Kaiming He. Non-local neural networks. In *CVPR*, 2018.
- Dirk Weissenborn, Oscar Täckström, and Jakob Uszkoreit. Scaling autoregressive video models. In *ICLR*, 2019.
- Bichen Wu, Chenfeng Xu, Xiaoliang Dai, Alvin Wan, Peizhao Zhang, Masayoshi Tomizuka, Kurt Keutzer, and Peter Vajda. Visual transformers: Token-based image representation and processing for computer vision. *arxiv*, 2020.
- Yuxin Wu and Kaiming He. Group normalization. In *ECCV*, 2018.
- Qizhe Xie, Minh-Thang Luong, Eduard Hovy, and Quoc V. Le. Self-training with noisy student improves imagenet classification. In *CVPR*, 2020.
- Xiaohua Zhai, Avital Oliver, Alexander Kolesnikov, and Lucas Beyer. S⁴L: Self-Supervised Semi-Supervised Learning. In *ICCV*, 2019a.
- Xiaohua Zhai, Joan Puigcerver, Alexander Kolesnikov, Pierre Ruysen, Carlos Riquelme, Mario Lucic, Josip Djolonga, Andre Susano Pinto, Maxim Neumann, Alexey Dosovitskiy, et al. A large-scale study of representation learning with the visual task adaptation benchmark. *arXiv preprint arXiv:1910.04867*, 2019b.
- Hengshuang Zhao, Jiaya Jia, and Vladlen Koltun. Exploring self-attention for image recognition. In *CVPR*, 2020.

Models	Dataset	Epochs	Base LR	LR decay	Weight decay	Dropout
ViT-B/{16,32}	JFT-300M	7	$8 \cdot 10^{-4}$	linear	0.1	0.0
ViT-L/32	JFT-300M	7	$6 \cdot 10^{-4}$	linear	0.1	0.0
ViT-L/16	JFT-300M	7/14	$4 \cdot 10^{-4}$	linear	0.1	0.0
ViT-H/14	JFT-300M	14	$3 \cdot 10^{-4}$	linear	0.1	0.0
R50x{1,2}	JFT-300M	7	10^{-3}	linear	0.1	0.0
R101x1	JFT-300M	7	$8 \cdot 10^{-4}$	linear	0.1	0.0
R152x{1,2}	JFT-300M	7	$6 \cdot 10^{-4}$	linear	0.1	0.0
R50+ViT-B/{16,32}	JFT-300M	7	$8 \cdot 10^{-4}$	linear	0.1	0.0
R50+ViT-L/32	JFT-300M	7	$2 \cdot 10^{-4}$	linear	0.1	0.0
R50+ViT-L/16	JFT-300M	7/14	$4 \cdot 10^{-4}$	linear	0.1	0.0
ViT-B/{16,32}	ImageNet-21k	90	10^{-3}	linear	0.03	0.1
ViT-L/{16,32}	ImageNet-21k	30/90	10^{-3}	linear	0.03	0.1
ViT-*	ImageNet	300	$3 \cdot 10^{-3}$	cosine	0.3	0.1

Table 3: Hyperparameters for training. All models are trained with a batch size of 4096 and learning rate warmup of 10k steps. For ImageNet we found it beneficial to additionally apply gradient clipping at global norm 1. Training resolution is 224.

附录

多头自注意力

标准 qkv 自注意力 (SA, Vaswani et al. (2017)) 是神经架构中常用的构建模块。对于输入序列 $\mathbf{z} \in \mathbb{R}^{N \times D}$ 中的每个元素, 我们计算序列中所有值 $\mathbf{v}$ 的加权和。注意力权重 A_{ij} 基于序列两个元素之间的成对相似度及其各自的查询 $\mathbf{q}^i$ 和键 $\mathbf{k}^j$ 表示。

$$[\mathbf{q}, \mathbf{k}, \mathbf{v}] = \mathbf{z} \mathbf{U}_{qkv} \quad \mathbf{U}_{qkv} \in \mathbb{R}^{D \times 3D_h}, \quad (5)$$

$$A = \text{softmax} \left(\frac{\mathbf{q} \mathbf{k}^\top}{\sqrt{D_h}} \right) \quad A \in \mathbb{R}^{N \times N}, \quad (6)$$

$$\text{SA}(\mathbf{z}) = A \mathbf{v}. \quad (7)$$

多头自注意力 (MSA) 是 SA 的一种扩展, 其中并行运行 k 个称为“头”的自注意力操作, 并投影其拼接后的输出。为了在改变 k 时保持计算量和参数数量不变, D_h (公式 5) 通常设置为 D/k 。

$$\text{MSA}(\mathbf{z}) = [\text{SA}_1(\mathbf{z}); \text{SA}_2(\mathbf{z}); \dots; \text{SA}_k(\mathbf{z})] \mathbf{U}_{msa} \quad \mathbf{U}_{msa} \in \mathbb{R}^{k \cdot D_h \times D} \quad (8)$$

B 实验细节

B.1 训练

表 3 总结了不同模型的训练设置。我们发现, 在 ImageNet 上从头开始训练模型时, 强正则化至关重要。若使用 Dropout, 则将其应用于除 qkv 投影之外的每个全连接层之后, 以及位置嵌入添加到补丁嵌入之后。混合模型的训练设置与其对应的 ViT 完全相同。最后, 所有训练均在分辨率 224 下进行。

B.1.1 微调

我们使用动量为 0.9 的 SGD 对所有 ViT 模型进行微调。我们对学习率进行了小规模网格搜索, 学习率范围见表 4。为此, 我们从训练集中划分出小的子集 (Pets 和 Flowers 为 10%, CIFAR 为 2%, ImageNet 为 1%) 作为开发集, 并在剩余数据上进行训练。对于最终结果, 我们在整个训练集上进行训练, 并在相应的测试数据上进行评估。对于 ResNets 和混合模型的微调, 我们采用完全相同的设置, 唯一的例外是 ImageNet, 其中我们在学习率扫描中额外添加了值 0.06。此外,

Dataset	Steps	Base LR
ImageNet	20 000	{0.003, 0.01, 0.03, 0.06}
CIFAR100	10 000	{0.001, 0.003, 0.01, 0.03}
CIFAR10	10 000	{0.001, 0.003, 0.01, 0.03}
Oxford-IIIT Pets	500	{0.001, 0.003, 0.01, 0.03}
Oxford Flowers-102	500	{0.001, 0.003, 0.01, 0.03}
VTAB (19 tasks)	2 500	0.01

Table 4: Hyperparameters for fine-tuning. All models are fine-tuned with cosine learning rate decay, a batch size of 512, no weight decay, and grad clipping at global norm 1. If not mentioned otherwise, fine-tuning resolution is 384.

对于 ResNets, 我们还运行了 Kolesnikov et al. (2020) 的设置, 并选取该运行与我们扫描中的最佳结果。最后, 除非另有说明, 所有微调实验均在 384 分辨率下运行 (在不同于训练的分辨率下进行微调是常见做法 (Kolesnikov et al., 2020))。

将 ViT 模型迁移到另一个数据集时, 我们移除整个头部 (两个线性层), 并将其替换为一个零初始化的线性层, 该层输出目标数据集所需的类别数。我们发现这种方法比仅重新初始化最后一层更稳健。

对于 VTAB, 我们遵循 Kolesnikov et al. (2020) 中的协议, 并对所有任务使用相同的超参数设置。我们使用 0.01 的学习率并训练 2500 步 (表 4)。我们通过针对两种学习率和两种调度策略进行小规模扫描, 并在 200 样本验证集上选择具有最高 VTAB 分数的设置来确定此配置。我们采用 Kolesnikov et al. (2020) 中的预处理方法, 但不使用特定任务的输入分辨率。相反, 我们发现 Vision Transformer 在所有任务中均能从高分辨率 (384×384) 中获益最多。

B.1.2 自监督

我们在初步的自监督实验中使用掩码补丁预测目标。为此, 我们通过以下方式破坏 50% 的补丁嵌入: 将其嵌入替换为可学习的 [mask] 嵌入 (80%)、随机其他补丁嵌入 (10%) 或保持原样 (10%)。这种设置与 Devlin et al. (2019) 用于语言的设置非常相似。最后, 我们利用相应的补丁表示来预测每个被破坏补丁的 3 位平均颜色 (即总共 512 种颜色)。

我们在 JFT 上使用批量大小 4096 训练自监督模型 100 万步 (约 14 个 epoch)。我们使用 Adam 优化器, 基础学习率为 $2 \cdot 10^{-4}$, 预热 10k 步, 并采用余弦学习率衰减。作为预训练的预测目标, 我们尝试了以下设置: 1) 仅预测平均 3 位颜色 (即 1 次 512 色预测), 2) 并行预测 16×16 补丁降采样至 4×4 版本的 3 位颜色 (即 16 次 512 色预测), 3) 使用 L2 损失对整个补丁进行回归 (即对 3 个 RGB 通道进行 256 次回归)。令人惊讶的是, 我们发现所有这些方法都相当有效, 尽管 L2 稍差一些。我们仅报告选项 1) 的最终结果, 因为它在少样本性能方面表现最佳。我们还尝试了 Devlin et al. (2019) 使用的 15% 破坏率, 但在我们的少样本指标上结果也略差。

最后, 我们想指出的是, 我们的掩码块预测实例化并不需要如此大量的预训练, 也不需要像 JFT 这样的大数据集, 就能在 ImageNet 分类任务上取得类似的性能提升。也就是说, 我们在 10 万步预训练后观察到下游性能的收益递减, 并且在 ImageNet 上进行预训练时也能看到类似的提升。

C 附加结果

我们报告了与论文中图表对应的详细结果。表 5 对应论文中的图 3, 展示了在不同规模数据集 (ImageNet、ImageNet-21k 和 JFT-300M) 上预训练的不同 ViT 模型的迁移性能。表 6 对应

		ViT-B/16	ViT-B/32	ViT-L/16	ViT-L/32	ViT-H/14
ImageNet	CIFAR-10	98.13	97.77	97.86	97.94	-
	CIFAR-100	87.13	86.31	86.35	87.07	-
	ImageNet	77.91	73.38	76.53	71.16	-
	ImageNet ReaL	83.57	79.56	82.19	77.83	-
	Oxford Flowers-102	89.49	85.43	89.66	86.36	-
	Oxford-IIIT-Pets	93.81	92.04	93.64	91.35	-
ImageNet-21k	CIFAR-10	98.95	98.79	99.16	99.13	99.27
	CIFAR-100	91.67	91.97	93.44	93.04	93.82
	ImageNet	83.97	81.28	85.15	80.99	85.13
	ImageNet ReaL	88.35	86.63	88.40	85.65	88.70
	Oxford Flowers-102	99.38	99.11	99.61	99.19	99.51
	Oxford-IIIT-Pets	94.43	93.02	94.73	93.09	94.82
JFT-300M	CIFAR-10	99.00	98.61	99.38	99.19	99.50
	CIFAR-100	91.87	90.49	94.04	92.52	94.55
	ImageNet	84.15	80.73	87.12	84.37	88.04
	ImageNet ReaL	88.85	86.27	89.99	88.28	90.33
	Oxford Flowers-102	99.56	99.27	99.56	99.45	99.68
	Oxford-IIIT-Pets	95.80	93.40	97.11	95.83	97.56

Table 5: Top1 accuracy (in %) of Vision Transformer on various datasets when pre-trained on ImageNet, ImageNet-21k or JFT300M. These values correspond to Figure 3 in the main text. Models are fine-tuned at 384 resolution. Note that the ImageNet results are computed without additional techniques (Polyak averaging and 512 resolution images) used to achieve results in Table 2.

name	Epochs	ImageNet	ImageNet ReaL	CIFAR-10	CIFAR-100	Pets	Flowers	exaFLOPs
ViT-B/32	7	80.73	86.27	98.61	90.49	93.40	99.27	55
ViT-B/16	7	84.15	88.85	99.00	91.87	95.80	99.56	224
ViT-L/32	7	84.37	88.28	99.19	92.52	95.83	99.45	196
ViT-L/16	7	86.30	89.43	99.38	93.46	96.81	99.66	783
ViT-L/16	14	87.12	89.99	99.38	94.04	97.11	99.56	1567
ViT-H/14	14	88.08	90.36	99.50	94.71	97.11	99.71	4262
ResNet50x1	7	77.54	84.56	97.67	86.07	91.11	94.26	50
ResNet50x2	7	82.12	87.94	98.29	89.20	93.43	97.02	199
ResNet101x1	7	80.67	87.07	98.48	89.17	94.08	95.95	96
ResNet152x1	7	81.88	87.96	98.82	90.22	94.17	96.94	141
ResNet152x2	7	84.97	89.69	99.06	92.05	95.37	98.62	563
ResNet152x2	14	85.56	89.89	99.24	91.92	95.75	98.75	1126
ResNet200x3	14	87.22	90.15	99.34	93.53	96.32	99.04	3306
R50x1+ViT-B/32	7	84.90	89.15	99.01	92.24	95.75	99.46	106
R50x1+ViT-B/16	7	85.58	89.65	99.14	92.63	96.65	99.40	274
R50x1+ViT-L/32	7	85.68	89.04	99.24	92.93	96.97	99.43	246
R50x1+ViT-L/16	7	86.60	89.72	99.18	93.64	97.03	99.40	859
R50x1+ViT-L/16	14	87.12	89.76	99.31	93.89	97.36	99.11	1668

Table 6: Detailed results of model scaling experiments. These correspond to Figure 5 in the main paper. We show transfer accuracy on several datasets, as well as the pre-training compute (in exaFLOPs).

论文中的图 5，展示了不同规模的 ViT、ResNet 和混合模型的迁移性能，以及其预训练的估计计算成本。

D 补充分析

D.1 ResNet 中 SGD 与 ADAM 的对比

ResNet 通常使用 SGD 进行训练，而我们采用 Adam 作为优化器则相当不寻常。在此，我们展示促使这一选择的实验。具体而言，我们比较了微调

Dataset	ResNet50		ResNet152x2	
	Adam	SGD	Adam	SGD
ImageNet	77.54	78.24	84.97	84.37
CIFAR10	97.67	97.46	99.06	99.07
CIFAR100	86.07	85.17	92.05	91.06
Oxford-IIIT Pets	91.11	91.00	95.37	94.79
Oxford Flowers-102	94.26	92.06	98.62	99.32
Average	89.33	88.79	94.01	93.72

Table 7: Fine-tuning ResNet models pre-trained with Adam and SGD.




图 8: Vision Transformer 不同模型维度的缩放。

两个在 JFT 上分别使用 SGD 和 Adam 预训练的 ResNet (50x1 和 152x2) 的性能。对于 SGD, 我们使用 Kolesnikov 等人 (2020) 推荐的超参数。结果见表 7。Adam 预训练在大多数数据集上以及平均性能上都优于 SGD 预训练。这证明了选择 Adam 作为在 JFT 上预训练 ResNet 的优化器的合理性。需要注意的是, 绝对数值低于 Kolesnikov 等人 (2020) 报告的结果, 因为我们仅预训练了 7 个 epoch, 而非 30 个。

D.2 Transformer 形状

我们对 Transformer 架构不同维度的扩展进行了消融实验, 以找出最适合扩展到超大模型的维度。图 8 显示了不同配置在 ImageNet 上的 5-shot 性能。所有配置均基于一个具有 8 层、 $D = 1024$ 、 $D_{MLP} = 2048$ 且块大小为 32 的 ViT 模型, 即所有曲线的交点。我们可以看到, 增加深度带来了最大的改进, 这种改进直到 64 层都清晰可见。然而, 在 16 层之后已经可以看到收益递减。有趣的是, 增加网络宽度似乎带来的变化最小。减小块大小从而增加有效序列长度显示出令人惊讶的稳健改进, 且未引入额外参数。这些发现表明, 计算量可能是比参数量更好的性能预测指标, 并且如果需要进行扩展, 应优先考虑深度而非宽度。总体而言, 我们发现按比例扩展所有维度能带来稳健的改进。

D.3 头部类型与类别标记

为了尽可能保持与原始 Transformer 模型的一致性, 我们使用了一个额外的 [class] token, 将其作为图像表示。该 token 的输出随后通过一个小型多层感知机 (MLP) 转换为类别预测, 其中单个隐藏层使用 tanh 作为非线性激活函数。

这一设计继承自用于文本的 Transformer 模型, 我们在正文中全程采用该设计。我们曾尝试仅使用图像块嵌入, 对其进行全局平均池化 (GAP), 再接一个线性分类器——这与 ResNet 的最终特征图类似——但效果非常差。然而, 我们发现这既不是由于额外的 token, 也不是由于 GAP 操作所致。相反,




图 9：类别标记与全局平均池化分类器的比较。两者表现相当，但需要不同的学习率。

Pos. Emb.	Default/Stem	Every Layer	Every Layer-Shared
No Pos. Emb.	0.61382	N/A	N/A
1-D Pos. Emb.	0.64206	0.63964	0.64292
2-D Pos. Emb.	0.64001	0.64046	0.64022
Rel. Pos. Emb.	0.64032	N/A	N/A

Table 8: Results of the ablation study on positional embeddings with ViT-B/16 model evaluated on ImageNet 5-shot linear.

性能差异完全可由需要不同的学习率来解释，见图 9。

D.4 位置编码

我们对使用位置嵌入编码空间信息的不同方式进行了消融实验。我们尝试了以下情况：

- 不提供位置信息：将输入视为块的集合。
- 一维位置嵌入：将输入视为按光栅顺序排列的块序列（本文其他所有实验的默认设置）。
- 二维位置嵌入：将输入视为二维图像块网格。在此情况下，学习两组嵌入，分别对应 X 轴和 Y 轴，即 X 嵌入和 Y 嵌入，每组大小为 $D/2$ 。然后，根据输入中图像块的坐标，拼接 X 和 Y 嵌入以得到该图像块的最终位置嵌入。
- 相对位置嵌入：考虑图像块之间的相对距离来编码空间信息，而非其绝对位置。为此，我们使用一维相对注意力机制，其中定义了所有可能图像块对的相对距离。因此，对于每一对给定的图像块（一个作为查询，另一个作为注意力机制中的键/值），我们有一个偏移量 $p_q - p_k$ ，每个偏移量关联一个嵌入。然后，我们简单地运行额外的注意力机制，使用原始查询（查询内容），但使用相对位置嵌入作为键。接着，我们将相对注意力的 logits 作为偏置项，并在应用 softmax 之前将其添加到主注意力（基于内容的注意力）的 logits 中。

除了不同的空间信息编码方式外，我们还尝试了将此类信息纳入模型的不同方法。对于一维和二维位置嵌入，我们尝试了三种不同情况：(1) 在主干网络之后、将输入馈送至 Transformer 编码器之前，直接将位置嵌入加到输入上




图 10: 使用不同超参数训练的模型的位置嵌入。

(本文其他所有实验中的默认设置); (2) 在每一层开始时学习并将位置嵌入加到输入上;
(3) 在每一层开始时将学习到的位置嵌入加到输入上 (各层之间共享)。

表 8 总结了在 ViT-B/16 模型上进行的这项消融研究的结果。我们可以看到, 虽然无位置嵌入的模型与有位置嵌入的模型之间性能差距较大, 但不同位置信息编码方式之间的差异微乎其微。我们推测, 由于我们的 Transformer 编码器处理的是图像块级输入而非像素级输入, 如何编码空间信息的差异变得不那么重要。更准确地说, 在图像块级输入中, 空间维度远小于原始像素级输入, 例如 14×14 对比 224×224 , 在这种分辨率下学习表示空间关系对于这些不同的位置编码策略来说同样容易。尽管如此, 网络学习到的特定位置嵌入相似性模式取决于训练超参数 (图 10)。




图 11: 各注意力头及网络深度对应的关注区域大小。针对 128 张示例图像, 通过计算查询像素与其他所有像素之间距离的加权平均值 (权重为注意力权重) 得到注意力距离。每个点表示某一层中 16 个注意力头之一在跨图像上的平均注意力距离。图像宽度为 224 像素。

D.5 经验计算成本

我们还关注这些架构在硬件上的实际运行速度, 由于通道宽度和缓存大小等细节, 理论 FLOPs 并不总能准确预测这一指标。为此,

我们在 TPUv3 加速器上对主要关注的模型进行推理速度计时；推理速度与反向传播速度之间的差异是一个与模型无关的常数因子。

图 12（左）展示了在不同输入尺寸下，单个核心每秒可处理的图像数量。每个点都指代在广泛批次大小范围内测得的峰值性能。可以看出，ViT 随图像尺寸变化的理论双二次缩放仅在最大模型于最高分辨率下才开始显现。

另一个感兴趣的量是每个模型能在单个核心上容纳的最大批次大小，较大的批次大小有利于扩展到大型数据集。图 12（右）展示了同一组模型的这一指标。这表明，大型 ViT 模型在内存效率方面相比 ResNet 模型具有明显优势。




图 12：左：不同架构在各种输入尺寸下的实际墙钟时间。ViT 模型的速度与类似的 ResNet 相当。右：不同架构在各种输入尺寸下，设备上单核可容纳的最大批大小。ViT 模型在内存效率上明显更优。

D.6 轴向注意力

轴向注意力 (Axial Attention) (Huang et al., 2020; Ho et al., 2019) 是一种简单而有效的技术, 用于在组织为多维张量的大输入上运行自注意力。轴向注意力的一般思想是执行多次注意力操作, 每次沿输入张量的单个轴进行, 而不是对输入的展平版本应用一维注意力。在轴向注意力中, 每次注意力混合沿特定轴的信息, 同时保持沿其他轴的信息独立。沿着这一思路, Wang et al. (2020b) 提出了 AxialResNet 模型, 其中 ResNet50 中所有核大小为 3×3 的卷积都被替换为轴向自注意力, 即行注意力和列注意力, 并辅以相对位置编码。我们实现了 AxialResNet 作为基线模型。³

此外, 我们修改了 ViT 以处理二维形状输入, 而非一维图像块序列, 并引入了 Axial Transformer 模块; 在该模块中, 自注意力后接 MLP 的结构被替换为行自注意力加 MLP, 再接列自注意力加 MLP。这以增加计算量为代

图 13 展示了 Axial ResNet、Axial-ViT-B/32 和 Axial-ViT-B/16 在 ImageNet 5-shot 线性评估上的性能, 这些模型均在 JFT 数据集上进行预训练, 横轴为预训练计算量, 包括 FLOPs 数量和推理时间 (每秒样本数)。我们可以看到, Axial-ViT-B/32 和 Axial-ViT-B/16 在性能上都优于对应的 ViT-B 模型, 但这以

³Our implementation is based on the open-sourced PyTorch implementation in <https://github.com/cshrddlam/axial-deeplab>. In our experiments, we reproduced the scores reported in (Wang et al., 2020b) in terms of accuracy, however, our implementation, similar to the open-source implementation, is very slow on TPUs. Therefore, we were not able to use it for extensive large-scale experiments. These may be unlocked by a carefully optimized implementation.




图 13: 基于 Axial-Attention 的模型在 ImageNet 5-shot 线性评估中的 top-1 准确率与其计算速度 (以 FLOPs 数计, 左) 及推理时间 (右) 的关系。

价。这是因为在 Axial-ViT 模型中, 每个具有全局自注意力的 Transformer 模块被两个 Axial Transformer 模块替代 (分别用于行和列自注意力); 尽管轴向情况下自注意力处理的序列长度更短, 但每个 Axial-ViT 模块多了一个 MLP。对于 AxialResNet, 虽然其在精度/计算量权衡方面表现合理 (图 13 左), 但其朴素实现在 TPU 上运行极慢 (图 13 右)。

D.7 注意力距离

为了理解 ViT 如何利用自注意力整合跨图像的信息, 我们分析了不同层中注意力权重跨越的平均距离 (图 11)。这种“注意力距离”类似于 CNN 中的感受野大小。在较低层中, 平均注意力距离在各头之间变化很大, 有些头关注图像的很大一部分, 而其他头则关注查询位置处或附近的小区域。随着深度增加, 所有头的注意力距离都在增加。在网络的后半部分, 大多数头广泛地关注各个 token。

D.8 注意力图

为了计算从输出 token 到输入空间的注意力图 (图 6 和图 14), 我们使用了 Attention Rollout (Abnar & Zuidema, 2020)。简而言之, 我们在所有头上对 ViT-L/16 的注意力权重进行平均, 然后递归地乘以所有层的权重矩阵。这考虑了通过所有层在 token 之间混合注意力的情况。

D.9 OBJECTNET 结果

我们还按照 Kolesnikov et al. (2020) 中的评估设置, 在 ObjectNet 基准上评估了我们的旗舰模型 ViT-H/14, 结果 top-5 准确率为 82.1%, top-1 准确率为 61.7%。

D.10 VTAB 细分

表 9 显示了在每个 VTAB-1k 任务上获得的分数。




图 14: 与图 6 类似的更多注意力图示例 (随机选取)。

Table 9: Breakdown of VTAB-1k performance across tasks.

	● Caltech101	● CIFAR-100	● DTD	● Flowers102	● Pets	● Sun397	● SVHN	● Camelyon	● EuroSAT	● Resisc45	● Retinopathy	● Clevr-Count	● Clevr-Dist	● DMLab	● dSpr-Loc	● dSpr-Ori	● KITTI-Dist	● sNORB-Azim	● sNORB-Elev	● Mean
ViT-H/14 (JFT)	95.3	85.5	75.2	99.7	97.2	65.0	88.9	83.3	96.7	91.4	76.6	91.7	63.8	53.1	79.4	63.3	84.5	33.2	51.2	77.6
ViT-L/16 (JFT)	95.4	81.9	74.3	99.7	96.7	63.5	87.4	83.6	96.5	89.7	77.1	86.4	63.1	49.7	74.5	60.5	82.2	36.2	51.1	76.3
ViT-L/16 (I21k)	90.8	84.1	74.1	99.3	92.7	61.0	80.9	82.5	95.6	85.2	75.3	70.3	56.1	41.9	74.7	64.9	79.9	30.5	41.7	72.7